

Site :  Luminy  St-Charles  St-Jérôme  Cht-Gombert  Aix-Montperrin  Aubagne-SATIS  
 Sujet Session de  1er semestre -  2ème semestre -  Session unique Durée de l'épreuve : 3h  
 Examen de  L1/ L2/ L3 -  M1/ M2 -  LP -  DU Nom Diplôme : MAS  
 Code Apogée du module : SMSAU02C Libellé du module : **Statistique**.  
 Document autorisé :  OUI- NON Calculette autorisée  OUI- NON

---

## Correction de l'examen à mi-parcours du Lundi 31 Octobre 2022.

*Les documents, notes de cours et calculatrices sont interdits, à l'exception d'une feuille A4 recto-verso. Le soin apporté à la rédaction sera un élément d'appréciation. Le barême est donné à titre purement indicatif.*

**Exercice 1 (5 points).** Soient  $X$  et  $Y$  des variables aléatoires **indépendantes** de loi gaussienne centrée réduite,  $X \sim Y \sim \mathcal{N}(0, 1)$ .

Le terme "indépendantes" manquait dans l'énoncé.

- Montrez que la loi du couple  $(X, Z) = (X, X^2 + Y^2)$  a pour densité

$$f_{(X,Z)}(x, z) = \frac{1}{2\pi} e^{-\frac{z}{2}} \frac{1}{\sqrt{z-x^2}} \mathbf{1}_{z \geq x^2}.$$

Soit  $h$  une fonction mesurable bornée de  $\mathbb{R}^2$  dans  $\mathbb{R}$

$$\begin{aligned} \mathbb{E}(h(X, Z)) &= \iint h(x, x^2 + y^2) \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right) dx dy \\ &= 2 \int_0^{+\infty} dy \int_{-\infty}^{+\infty} dx h(x, x^2 + y^2) \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right) \end{aligned}$$

On fait le changement de variable  $(x, y) \in \mathbb{R} \times \mathbb{R}^+ \mapsto (u, v) = (x, x^2 + y^2) \in D$ . On a  $x = u, y = \sqrt{v - u^2}$ . Le déterminant de la matrice Jacobienne vaut en valeur absolue  $1/2\sqrt{v - u^2}$ , et le domaine  $D = \{(u, v) \in \mathbb{R} \times \mathbb{R}^+ ; u^2 \leq v\}$ . On obtient donc :

$$\mathbb{E}(h(X, Z)) = \iint_D h(u, v) \frac{1}{2\pi} \exp\left(-\frac{v}{2}\right) \frac{1}{\sqrt{v-u^2}} du dv$$

et la densité du couple  $(X, Z)$  est la fonction  $\frac{e^{-z/2}}{2\pi\sqrt{z-x^2}} \mathbf{1}_D(x, z)$

- Quelle est la loi de  $X^2 + Y^2$ ,  
Par définition de la loi du  $\chi_d^2$ ,  $X^2 + Y^2 \sim \chi_2^2$ .

3. Montrer que la loi conditionnelle de  $X | X^2 + Y^2 = z$  a pour densité

$$f_{X|X^2+Y^2=z}(x) = \frac{1}{\pi} \frac{1}{\sqrt{z-x^2}} \mathbb{1}_{x^2 \leq z}.$$

La densité conditionnelle de  $X | X^2 + Y^2 = z$  est la fonction  $x \in [-\sqrt{z}, +\sqrt{z}] \mapsto \frac{1}{C(z)\sqrt{z-x^2}}$ , où la constante de normalisation  $C(z)$  vaut

$$C(z) = \int_{-\sqrt{z}}^{\sqrt{z}} \frac{1}{\sqrt{z-x^2}} dx = \int_{-1}^1 \frac{1}{\sqrt{1-u^2}} du = \int_{-\pi/2}^{\pi/2} d\theta = \pi,$$

où le deuxième égalité vient du changement de variable  $u = x/\sqrt{z}$ , et la troisième du changement de variable  $u = \sin(\theta)$ .

4. En déduire que

$$\mathbb{E}[|X| | X^2 + Y^2] = 2 \frac{\sqrt{X^2 + Y^2}}{\pi}$$

On a donc

$$\mathbb{E}[|X| | X^2 + Y^2 = z] = \int_{-\sqrt{z}}^{\sqrt{z}} \frac{|x|}{\pi \sqrt{z-x^2}} dx = 2\sqrt{z} \int_0^1 \frac{u}{\pi \sqrt{1-u^2}} du = 2\sqrt{z} \int_0^{\pi/2} \sin(\theta) \frac{d\theta}{\pi} = \frac{2}{\pi} z,$$

en effectuant les mêmes changements de variable qu'en question 3. On a donc

$$\mathbb{E}[|X| | X^2 + Y^2] = \frac{2(X^2 + Y^2)}{\pi}.$$

**Exercice 2 (8 points).** On considère un échantillon indépendant et identiquement distribué (i.i.d.)  $(X_i)_{1 \leq i \leq n}$ , avec  $X_1$  de densité

$$f_\theta(x) = \frac{2x}{\theta^2} \mathbb{1}_{[0,\theta]}(x), \quad \text{avec } \theta > 0 \text{ un paramètre inconnu.}$$

1. On note  $X_{(n)} = \max_{1 \leq i \leq n} X_i$ .

(a) Calculer la fonction de répartition de  $X_{(n)}$ . Quelle est la densité de  $X_{(n)}$  ?

Les  $(X_i)_{1 \leq i \leq n}$  étant i.i.d., pour tout  $t \in \mathbb{R}$ ,  $\mathbb{P}_\theta(X_{(n)} \leq t) = \mathbb{P}_\theta(X_1 \leq t)^n$ , avec

$$\mathbb{P}_\theta(X_1 \leq t) = \begin{cases} 0 & \text{si } t \leq 0, \\ 1 & \text{si } t \geq \theta, \\ \int_0^t \frac{2x}{\theta^2} dx = \frac{t^2}{\theta^2} & \text{si } 0 \leq t \leq \theta. \end{cases}$$

On a donc

$$\mathbb{P}_\theta(X_{(n)} \leq t) = \begin{cases} 0 & \text{si } t \leq 0, \\ 1 & \text{si } t \geq \theta, \\ \frac{t^{2n}}{\theta^{2n}} & \text{si } 0 \leq t \leq \theta. \end{cases}$$

et la densité de  $X_{(n)}$  vaut donc  $2n \frac{t^{2n-1}}{\theta^{2n}} \mathbb{1}_{[0,\theta]}(t)$ .

- (b) Donner les deux premiers moments de  $X_{(n)}$ . En déduire sa variance.

On a

$$\mathbb{E}_\theta(X_{(n)}) = \int_0^\theta 2n \frac{t^{2n}}{\theta^{2n}} dt = \frac{2n}{2n+1} \theta.$$

$$\mathbb{E}_\theta(X_{(n)}^2) = \int_0^\theta 2n \frac{t^{2n+1}}{\theta^{2n}} dt = \frac{n}{n+1} \theta^2.$$

$$\text{var}_\theta(X_{(n)}) = \left[ \frac{n}{n+1} - \left( \frac{2n}{2n+1} \right)^2 \right] \theta^2 = \frac{n}{n+1} \frac{1}{(2n+1)^2} \theta^2.$$

- (c) Quel est le risque quadratique de  $X_{(n)}$  comme estimateur de  $\theta$  ?

$$\begin{aligned} R_{X_{(n)}}(\theta) &= \mathbb{E}_\theta [(X_{(n)} - \theta)^2] = \text{biais}^2 + \text{variance} \\ &= \left( \frac{2n}{2n+1} - 1 \right)^2 \theta^2 + \frac{n}{n+1} \frac{1}{(2n+1)^2} \theta^2 = \frac{\theta^2}{(2n+1)^2}. \end{aligned}$$

- (d) Montrer que  $X_{(n)}$  converge en probabilité vers  $\theta$ .

Pour tout  $\epsilon > 0$ , l'inégalité de Markov donne

$$\mathbb{P}_\theta(|X_{(n)} - \theta| \geq \epsilon) \leq \frac{1}{\epsilon^2} \mathbb{E}_\theta [(X_{(n)} - \theta)^2] = \frac{1}{\epsilon^2} \frac{\theta^2}{(2n+1)^2}.$$

On en déduit que  $X_{(n)}$  converge en probabilité vers  $\theta$ .

2. On pose maintenant  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ .

- (a) Montrer que  $\frac{3}{2}\bar{X}_n$  est un estimateur sans biais et consistant de  $\theta$ .

$\mathbb{E}_\theta(X_1) = \mathbb{E}_\theta(X_{(1)}) = 2\theta/3$ . Par linéarité de l'espérance,  $\mathbb{E}_\theta(\bar{X}_n) = \mathbb{E}_\theta(X_1) = 2\theta/3$ .  $3\bar{X}_n/2$  est donc un estimateur sans biais de  $\theta$ .

Les  $(X_i)_{1 \leq i \leq n}$  étant i.i.d. et intégrable,  $\bar{X}_n$  converge p.s. vers  $\mathbb{E}_\theta(X_1)$  par la loi forte des grands nombres, et  $3\bar{X}_n/2$  est donc un estimateur consistant de  $\theta$ .

- (b) Quel est le risque quadratique de  $\frac{3}{2}\bar{X}_n$  comme estimateur de  $\theta$  ?

$3\bar{X}_n/2$  étant sans biais, son risque est égal à sa variance. Les  $(X_i)_{1 \leq i \leq n}$  étant i.i.d. , on a alors

$$R_{3\bar{X}_n/2}(\theta) = \frac{9}{4n} \text{var}_\theta(X_1) = \frac{9}{4n} \text{var}_\theta(X_{(1)}) = \frac{9}{4n} \frac{\theta^2}{2(9)} = \frac{\theta^2}{8n}.$$

- (c) Qui de  $X_{(n)}$  ou  $\frac{3}{2}\bar{X}_n$  choisiriez-vous pour estimer  $\theta$  ?

On vérifie facilement que pour tout  $n \geq 1$  ,  $3n \leq (2n+1)^2$ . On a donc pour tout  $n \geq 1$  et tout  $\theta \in \mathbb{R}$ ,  $R_{3\bar{X}_n/2}(\theta) \geq R_{X_{(n)}}(\theta)$ .  $X_{(n)}$  est un meilleur estimateur de  $\theta$  que  $3\bar{X}_n/2$ .

3. On s'intéresse à une estimation ensembliste de  $\theta$  en utilisant l'estimateur  $X_{(n)}$ .

- (a) Montrer que  $\frac{X_{(n)}}{\theta}$  est un pivot pour l'estimation de  $\theta$ .

Pour tout  $t \in \mathbb{R}$ ,

$$\mathbb{P}_\theta \left( \frac{X_{(n)}}{\theta} \leq t \right) = \mathbb{P}_\theta(X_{(n)} \leq \theta t) = \begin{cases} 0 & \text{si } t \leq 0, \\ 1 & \text{si } t \geq 1, \\ t^{2n} & \text{si } 0 \leq t \leq 1. \end{cases}$$

La loi de  $X_{(n)}/\theta$  ne dépend donc pas de  $\theta$ , i.e.  $X_{(n)}/\theta$  est un pivot pour l'estimation de  $\theta$ .

(b) Construire un intervalle de confiance pour  $\theta$  de niveau  $(1 - \alpha)$ , basé sur  $X_{(n)}$ .

Soit  $t$  tel que  $\mathbb{P}_\theta \left( \frac{X_{(n)}}{\theta} \geq t \right) = 1 - \alpha$ . D'après ce qui précède, on a  $t = \alpha^{1/2n}$ , et pour tout  $\theta$ ,

$$\mathbb{P}_\theta(0 \leq \theta \leq \alpha^{-1/2n} X_{(n)}) = 1 - \alpha.$$

Remarque : d'autres choix sont possibles, mais l'intervalle choisi ici est celui dont la longueur est minimale.

4. Nous cherchons maintenant à déterminer une estimation ensembliste de  $\theta$  à partir de  $\bar{X}_n$ .

(a) Montrer que  $\frac{\sqrt{8n}}{\sqrt{3}} \frac{\frac{3}{2}\bar{X}_n - \theta}{\theta}$  est un pivot asymptotique pour l'estimation de  $\theta$ .

Une autre erreur dans l'énoncé... Le facteur  $\sqrt{3}$  doit être supprimé.

Les  $(X_i)_{1 \leq i \leq n}$  étant i.i.d. et de carré intégrable, le théorème de la limite centrale affirme que  $\frac{\frac{3}{2}\bar{X}_n - \theta}{\sqrt{\text{var}(\frac{3}{2}\bar{X}_n)}}$  converge en loi vers une loi  $\mathcal{N}(0, 1)$ . De plus, on a vu que  $\text{var}(\frac{3}{2}\bar{X}_n) = \theta^2/8n$ .

Par conséquent,  $\sqrt{8n} \frac{\frac{3}{2}\bar{X}_n - \theta}{\theta}$  converge en loi vers une loi  $\mathcal{N}(0, 1)$  indépendante de  $\theta$ , et est donc un pivot asymptotique.

Remarque : En fait  $\frac{\frac{3}{2}\bar{X}_n - \theta}{\theta} = \sum_{i=1}^n Y_i - 1$  où les variables  $Y_i = 3X_i/2\theta$  sont i.i.d. de loi indépendante de  $\theta$ . Par conséquent  $\frac{\frac{3}{2}\bar{X}_n - \theta}{\theta}$  est un pivot de  $\theta$  quelle que soit la valeur de  $n$ . Mais on ne connaît pas sa loi à  $n$  fixé. On peut toutefois approcher cette loi par la méthode de Monte-Carlo.

(b) En déduire un intervalle de confiance pour  $\theta$  de niveau asymptotique  $(1 - \alpha)$ , basé sur  $\bar{X}_n$ .

Soit  $t_{1-\frac{\alpha}{2}}$  le quantile d'ordre  $1 - \frac{\alpha}{2}$  de la loi  $\mathcal{N}(0, 1)$ . Quand  $n \rightarrow \infty$ , on a

$$\begin{aligned} & \mathbb{P} \left[ \left| \sqrt{8n} \frac{\frac{3}{2}\bar{X}_n - \theta}{\theta} \right| \leq t_{1-\frac{\alpha}{2}} \right] \simeq 1 - \alpha \\ \iff & \mathbb{P} \left[ \frac{\frac{3}{2}\bar{X}_n}{1 + \frac{t_{1-\frac{\alpha}{2}}}{\sqrt{8n}}} \leq \theta \leq \frac{\frac{3}{2}\bar{X}_n}{1 - \frac{t_{1-\frac{\alpha}{2}}}{\sqrt{8n}}} \right] \simeq 1 - \alpha \end{aligned}$$

**Exercice 3 (7 points).** Soit  $\theta \in \mathbb{R}$  un paramètre inconnu. On considère  $X_1, \dots, X_n$  un échantillon i.i.d. de loi gaussienne centrée en  $\theta$  et de variance 1, donc  $X_i \sim \mathcal{N}(\theta, 1)$ .

1. Dans ce modèle,

(a) Quelle est la vraisemblance  $L(\theta)$  ?

$$L(\theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp \left( -\frac{1}{2}(X_i - \theta)^2 \right) = \frac{1}{\sqrt{2\pi}^n} \exp \left( -\frac{1}{2} \sum_{i=1}^n (X_i - \theta)^2 \right).$$

(b) Montrer que l'information de Fisher vaut  $n$ .

$$\ell(\theta) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{i=1}^n (X_i - \theta)^2, \quad \ell'(\theta) = \sum_{i=1}^n (X_i - \theta).$$

$$\ell''(\theta) = -n, \quad I_n(\theta) = \mathbb{E}_\theta[-\ell''(\theta)] = n.$$

- (c) Montrer que  $\hat{\theta}_n = \bar{X}_n$  est l'estimateur du maximum de vraisemblance (EMV) de  $\theta$ , et qu'il est efficace.

$$\ell'(\theta) = 0 \iff \sum_{i=1}^n X_i = n\theta.$$

$\bar{X}_n$  est donc l'estimateur du maximum de vraisemblance de  $\theta$ .

$$\text{var}_\theta(\bar{X}_n) = \frac{\text{var}_\theta(X_1)}{n} = \frac{1}{n} = I_n(\theta)^{-1}.$$

$\bar{X}_n$  est efficace.

- (d) Quelle est la loi de  $\sqrt{n}(\bar{X}_n - \theta)$  ?

Les  $X_i$  étant i.i.d. de loi  $\mathcal{N}(\theta, 1)$ , leur somme est une variable normale de moyenne  $n\mathbb{E}_\theta(X_1) = n\theta$ , et de variance  $n\text{var}_\theta(X_1) = n$ . Par conséquent,  $\sqrt{n}(\bar{X}_n - \theta) \sim \mathcal{N}(0, 1)$ .

2. On s'intéresse au paramètre inconnu  $\eta$  défini par  $\eta^3 = \theta$ .

- (a) Montrer que la vraisemblance  $\tilde{L}$  pour ce paramètre est donnée par  $\tilde{L}(\eta) = L(\eta^3)$ .

En fonction de  $\eta$ , les  $X_i$  sont i.i.d. de loi  $\mathcal{N}(\eta^3, 1)$ , on a évidemment  $\tilde{L}(\eta) = L(\eta^3)$ .

- (b) Quelle est l'information de Fisher pour ce nouveau paramètre ? Quelle est sa valeur pour  $\eta = 0$  ?

On a  $\tilde{\ell}(\eta) = \ell(\eta^3)$ ,  $\tilde{\ell}'(\eta) = 3\eta^2\ell'(\eta^3)$ ,

$$\tilde{\ell}''(\eta) = 6\eta\ell'(\eta^3) + 9\eta^4\ell''(\eta^3) = 6\eta \sum_{i=1}^n (X_i - \eta^3) - 9n\eta^4.$$

$$\tilde{I}_n(\eta) = 6\eta\mathbb{E}_\eta \left[ \sum_{i=1}^n (\eta^3 - X_i) \right] + 9n\eta^4 = 9n\eta^4, \text{ et } \tilde{I}_n(0) = 0.$$

- (c) Montrer que l'EMV  $\hat{\eta}_n$  de  $\eta$  est tel que  $\hat{\eta}_n^3 = \hat{\theta}_n$ .

Puisque  $\tilde{\ell}(\eta) = \ell(\eta^3)$ ,  $\hat{\eta}_n$  maximise  $\eta \mapsto \ell(\eta^3)$  et donc  $\hat{\eta}_n^3 = \hat{\theta}_n$ .

3. On suppose que  $\eta \neq 0$ . Montrer alors qu'asymptotiquement

$$\sqrt{n}(\hat{\eta}_n - \eta) \xrightarrow{\text{loi}} \mathcal{N}\left(0, \left(\frac{1}{3\eta^2}\right)^2\right).$$

Si  $\eta \neq 0$ ,  $\tilde{I}_n(\eta) > 0$ , et on peut appliquer les résultats asymptotiques sur les EMV pour en déduire que  $\sqrt{\tilde{I}_n(\eta)}(\hat{\eta}_n - \eta) = 3\eta^2\sqrt{n}(\hat{\eta}_n - \eta)$  converge en loi vers une loi  $\mathcal{N}(0, 1)$ .

On peut aussi utiliser la méthode Delta, en utilisant le fait que  $\hat{\eta}_n = \varphi(\hat{\theta}_n)$ , où  $\varphi(x) = x^{1/3}$  est dérivable pour  $x \neq 0$ . On en déduit que  $\sqrt{n}(\hat{\eta}_n - \eta)$  converge en loi vers une loi normale de variance  $\frac{\varphi'(\theta)^2}{I_1(\theta)} = \left(\frac{1}{3\theta^{4/3}}\right)^2 = \frac{1}{9\eta^4}$ .

4. On suppose maintenant que  $\eta = 0$ .

- (a) Quelle est la loi de  $\sqrt{n}\hat{\theta}_n$ ? En déduire que  $n^{(1/6)}\hat{\eta}_n$  a une loi qui ne dépend pas de  $n$ , et comparer au résultat de la question 3.

$\sqrt{n}\hat{\theta}_n \sim \mathcal{N}(0, 1)$ . Comme  $\sqrt{n}\hat{\theta}_n = (n^{1/6}\hat{\eta}_n)^3$ , on en déduit que  $n^{1/6}\hat{\eta}_n$  a même loi que  $Z^{1/3}$ , où  $Z \sim \mathcal{N}(0, 1)$ .

(b) Montrer que  $n^{(1/6)}\hat{\eta}_n$  a pour densité

$$e^{-(t^6/2)} \frac{3t^2}{\sqrt{2\pi}}.$$

Soit  $h$  une fonction mesurable bornée.

$$\mathbb{E}(h(n^{1/6}\hat{\eta}_n)) = \mathbb{E}(h(Z^{1/3})) = \int h(z^{1/3}) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz.$$

On pose  $t = z^{1/3} \iff z = t^3$ .

$$\mathbb{E}(h(n^{1/6}\hat{\eta}_n)) = \int h(t) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^6}{2}\right) 3t^2 dt,$$

ce qui donne le résultat.